

ALIGNEMENT MULTIPLE PROGRESSIF (MÉTHODE CLUSTAL)

Implémentation par programmation dynamique exacte et
embranchement séquentiel

Présenté par : Lina MAGROUN

UE : Gestion de projet et Programmation avancé

Formation : M2 Bioinformatique


Responsables : Y. Mohseni, K. Bouyioukos, J.C.Gelly, P. Fuchs

Année universitaire 2026–2027

Sommaire

1. Introduction & Objectifs du Projet
2. Matériel & Méthodes Algorithmiques
3. Résultats & Évaluation des Performances
4. Discussion & Limites
5. Conclusion & Perspectives

1. Introduction & Objectifs du Projet



1. L'Alignement Multiple

- Identifier les **régions conservées** au cours de l'évolution.
- **Limite** : L'algorithme exact (Needleman & Wunsch) est **inapplicable** pour N séquences (**complexité exponentielle**).

2. Méthode CLUSTAL (Higgins & Sharp, 1989)

- **Solution** : Approche **heuristique progressive** par itérations.
- **Principe** : Assemblage successif des séquences en suivant la **topologie d'un arbre guide**.

3. Objectifs du projet

Réimplémenter ce pipeline avec deux modifications majeures :

- **L'arbre guide** : **Embranchement séquentiel glouton** (intégration sur un **profil unique** au lieu de l'UPGMA).
- **L'alignement** : Modèle exact de Gotoh à **pénalités affines** (distingue l'ouverture et l'extension pour une meilleure **fidélité biologique**).

2. Matériel & Méthodes Algorithmiques


Architecture du Pipeline - Pipeline développé en Python 3

1. Lecture FASTA & Paramètres

- **Fichier d'entrée** : chargement des séquences **p53** au format **FASTA** (**UniProt**, avec la séquence tronquée du cheval).
- **Analyse de l'alphabet** : scan des résidus pour différencier **ADN** et **protéines** et assigner le barème adapté.
- **PAM250 décalée (+8)** : conversion des scores de substitution en distances par la formule **25 - score**.

2. Alignement par paires (Gotoh)

- **Pénalités affines** : dissociation stricte entre **ouverture** d'un gap et **extension**.
- **3 matrices (M, I_x et I_y)** : remplissage simultané par **programmation dynamique** (complexité en $O(L^2)$).



Workflow global de l'alignement multiple progressif

2. Matériel & Méthodes Algorithmiques


Architecture du Pipeline - Pipeline développé en Python 3

3. Arbre Guide (Glouton)

- **Matrice de similarité** : calcul des scores 2 à 2 sur la demi-matrice supérieure (score = **Identités** – **Gaps** × **Pénalité**).
- **Embranchement séquentiel** : sélection du couple initial le plus proche, puis ajout glouton des séquences restantes (alternative à UPGMA).
- **Représentation de l'arbre** : génération de la topologie au format **Newick** et affichage en arbre **ASCII** dans le terminal pour valider l'ordre d'intégration.

4. Alignement Progressif (Séquence-Profil)

- **Alignement itératif** : ajout progressif de chaque séquence contre le profil via l'algorithme de **Gotoh** à 3 matrices (M, I_x, I_y).
- **Conservation des gaps** : les espaces déjà insérés lors des étapes précédentes sont **figés** et **conservés à l'identique**.
- **Arithmétique entière** : multiplication des pénalités par **K** (taille du profil) pour éliminer les nombres à virgule (**float**).
- **Backtracking exact** : élimination des erreurs d'arrondi machine lors de la remontée dans les matrices.



Workflow global de l'alignement multiple progressif

3. Résultats & Évaluation des Performances

3.1 Topologie de l'Arbre Guide

- **Paire initiale** : Regroupement **Humain / Macaque** (score maximal de 376).
- **Forme en "peigne"** : Ajout **séquence par séquence** (aucune formation de sous-groupes indépendants).
- **Intégration finale** : Le **cheval** est rattaché en **dernière position** (score minimal de 145).




Figure 1 : Dendrogramme de l'arbre guide

3. Résultats & Évaluation des Performances

3.2 Alignement multiple final

- **Longueur finale : 411 colonnes** au total (résidus + gaps).
- **Backtracking sans perte :** Conservation totale de l'information (ex. **393 résidus + 18 gaps = 411**).
- **Taux de gaps :** Marqueur de distance évolutive (**4,4 % Macaque**) et de troncature (**31,9 % Cheval**).

Tableau 2. Statistiques d'alignement final (411 colonnes)

Séquence	Longueur d'origine	Gaps insérés	Proportion de gaps
p53_Humain	393	18	4.4 %
p53_Macaque	393	18	4.4 %
p53_Lapin	391	20	4.9 %
p53_Rat	391	20	4.9 %
p53_Souris	390	21	5.1 %
p53_Vache	386	25	6.1 %
p53_Chien	381	30	7.3 %
p53_Poisson_Zebre	373	38	9.2 %
p53_Poulet	367	44	10.7 %
p53_Cheval	280	131	31.9 %

3. Résultats & Évaluation des Performances

3.3 Mesures de performances

- **Complexité en $O(L^2)$ confirmée** : Le temps de calcul quadruple à chaque doublement de taille.
- **Étape la plus lourde** : La matrice initiale monopolise 72 % du temps global (test sur 12 séquences).
- **Arbre glouton** : Coût temporel nul (0,0000 s).


Tableau 3. Temps d'exécution en fonction de la longueur (N=5)

Longueur des séquences (L)	Temps de calcul total	Facteur d'accroissement
50 résidus	0.0345 s	-
100 résidus	0.1355 s	~ x 3.92
200 résidus	0.5493 s	~ x 4.05
300 résidus	1.2674 s	~ x 2.30

Tableau 4. Décomposition du temps selon le nombre de séquences (L=50)

Nb de séquences (N)	Matrice	Arbre	Alignement progressif	Temps Total	Part Matrice
3 séquences	0.0065 s	0.0000 s	0.0055 s	0.0120 s	54.1 %
5 séquences	0.0219 s	0.0000 s	0.0126 s	0.0346 s	63.3 %
8 séquences	0.0610 s	0.0000 s	0.0283 s	0.0893 s	68.3 %
12 séquences	0.1431 s	0.0000 s	0.0544 s	0.1975 s	72.4 %

4. Discussion & Limites



Pénalités affines (Gotoh)

- **Regroupement biologiques** des insertions et délétions.
- **Alignement cohérent** du cheval tronqué (préservation des autres taxons).
- Coût spatial $O(L^2)$: **Myers & Miller** requis pour les génomes.

Arbre glouton & Artéfact

- Ajout successif sur profil unique (alternative à UPGMA).
- **Intégration tardive** du cheval.
- **Impact de la troncature** (séquence incomplète via **UniProt**)


Stabilité informatique

- Les **erreurs d'arrondi** sur les flottants bloquent le backtracking.
- **Arithmétique entière** : multiplication par **K** séquences.
- Élimination des erreurs d'arrondi : **stabilité numérique** de la reconstruction.

5. Conclusion & Perspectives

Conclusion

- **Outil d'alignement fonctionnel** : principes de CLUSTAL (PAM250, conservation des gaps)
- **Pénalités affines** : gestion efficace des séquences incomplètes (cas du cheval)
- **Complexité en $O(L^2)$** : confirmée par les mesures de temps
- **Arithmétique entière** : stabilité du backtracking (aucune erreur d'arrondi)



Perspectives

- **Optimisation mémoire** : intégration de **Myers & Miller** (espace linéaire pour aligner des génomes complets)
- **Phylogénie** : implémenter le **Neighbor-Joining** pour stabiliser l'arbre face aux séquences tronquées

| Merci de votre attention ! |

Présenté par : Lina MAGROUN

UE : Gestion de projet et Programmation avancé

Formation : M2 Bioinformatique

Responsables : Y. Mohseni, K. Bouyioukos, J.C.Gelly, P. Fuchs

Année universitaire 2026–2027

Références Bibliographiques

Higgins, D.G. et Sharp, P.M. (1989) Fast and sensitive multiple sequence alignments on a microcomputer. *CABIOS*, 5(2), 151-153.

Gotoh, O. (1982). An improved algorithm for matching biological sequences. *Journal of Molecular Biology*, 162(3), 705–708.

UniProt Consortium. (2021). UniProt: the universal protein knowledgebase in 2021. *Nucleic Acids Research*, 49(D1), D480–D489.